

期中作業說明

AI 生成影像能否改善少樣本影像分類？

為期七週 · 分三次繳交 · 適用大四與碩士班

寫在前面：為什麼要設計這份作業?!

這份文件是我們這門課中唯一的一次作業(期中)，請完整讀過一次，之後每次繳交前再回頭對照一次檢查清單。

本次作業分成一個連續七週、分三次繳交的作業流程，而不是三份互不相干的習題。理由很簡單：電腦視覺這門課真正難學的，從來不是把某個模型跑起來，而是在一個開放的問題上設計出公平的比較、誠實地報告結果，並且說得出「為什麼」。這三件事沒辦法用一次性的作業就能達成，只能靠同一個題目反覆深入。

三次繳交的邏輯如下：

1. 第一次，各位要先把「資料進得來」這件事做對：少樣本要怎麼輸入、解析度不一致要怎麼處理、樣本不足要怎麼補。擴增方法我不給答案，請各位自己想一個出來。
2. 第二次，各位要從第一次的結果中診斷出真正的瓶頸，把它寫成一個明確的問題，提出初步解法，並且動手做出來。
3. 第三次，各位要改用 diffusion model 生成假樣本來擴充訓練資料，訓練模型，然後和第一次、第二次的模型在一整組指標上進行比較。

我要先把最重要的一句話講在前面：這份作業的評分重心是「解釋為什麼」，不是「數字有沒有變高」。第三次繳交的配分裡，分析與解釋的比重高於任何一項效能數字。做出一個沒有提升但解釋得清清楚楚的結果，分數會高於一個提升了卻說不出原因的結果。

關於算力，請不用擔心

第一次與第二次繳交，各位在一般筆電的 CPU 上就能完成全部工作。

第三次繳交需要 GPU 來跑 diffusion 生成。各位在一般筆電的 CPU 或一般 GPU 上就能完成全部工作，可以不需要租用 GPU (如 Google Colab 上執行)。

課程的重點在實驗設計與分析，不在誰有比較好的顯示卡。

一、時程與配分

三次繳交的時間與權重如下。請特別注意，第一次繳交是後面兩次的地基，如果第一次的實驗流程沒有做對，第二、三次會非常辛苦。

繳交次序	繳交時間	內容	配分
第一次	第 4 週	少樣本輸入管線與自訂擴增方法(電子繳交)	25%
第二次	第 7 週	問題診斷、提出解法並實作(電子繳交)	20%
第三次	第 10 週	期末報告、程式(電子繳交)	25%

以上三次作業佔本門課成績 55%，另外還有一次的專業科技論文報告佔 40%；同學們以 2 人為一組自行分組。

三次繳交之間如何銜接

為了讓比較成立，我要各位在整個學期維持同一套模型命名，三次報告都用這組名稱：

代號	模型	產出時機
M0	助教提供的影像	第一次繳交
M1	M0 + 各組自訂的擴增方法	第一次繳交，codes & 3 頁 PDF
M2	M1 + 第二次提出的改良解法	第二次繳交，codes & 6 頁 PDF (包含第一次)
M3	M2 + diffusion 生成資料	第三次繳交，codes & 10 頁 PDF (包含前二次)

二、資料與環境

資料集

助教會提供 20 個 classes、每個 class 有 10~30 張不等，用作 Ground Truth (GT)的 training images，3 張作為 validation 的 images。測試集不提供，將用來評量各位繳交 models 時判斷好壞的評分測驗結果，請注意三件事：

1. 這些訓練影像的解析度與長寬比是刻意不統一的，範圍大約從 96×72 到 1024×768 都有，也包含少數模糊或曝光不佳的樣本。這不是資料瑕疵，這是各位第一次作業要處理的核心問題之一。
2. 驗證集(validation set)是各位用來將訓練結果，評量效果的重要資料集。
3. 測試集是隨機在這 20 個 classes 中，由助教事先準備好但不曾出現在 GT 訓練資料集中的照片。會隨機挑選出 images 來進行實測與跑分使用，每一類的測試集內會有 3 張 images。

模型與環境

1. 特徵擷取：各位可使用 ImageNet 預訓練的 ResNet-18 來進行。但前處理設定由各組自己決定，這正是第一次作業的重點。

- 分類器：以 Logistic Regression 為共同的基礎分類器。第二次繳交起可以更換，但必須同時保留 Logistic Regression 的結果作為對照。
- 環境：Python 3.11、Jupyter Notebook、PyTorch（CPU 即可）、NumPy、scikit-learn、Matplotlib。
- 生成模型（僅第三次使用）：Stable Diffusion 1.5，設定與流程見第五節。

三、第一次繳交：少樣本輸入管線與自訂擴增方法

第 4 週繳交 | 占 25%

這一次沒有 diffusion，也不准使用任何生成模型。我要各位先把最基本、也最常被忽略的那一段做對。

我要各位回答的三個問題

	問題	各位要做出的東西
Q1	少樣本要怎麼「輸入」？	一條可重現的資料載入與前處理管線，並說明每個決定的理由。
Q2	解析度不一致要怎麼處理？	至少 3 種尺寸正規化策略的實作與量化比較。
Q3	樣本不夠要怎麼補？	一個各組自行設計的擴增方法，以及它與傳統擴增的對照。

Q1 少樣本的輸入管線

在只有每類 10~30 張影像的情況下，前處理的每一個小決定都會被放大。請把下列決定明確寫在報告裡，而不是藏在程式碼中：

- 讀圖與色彩空間：如何處理灰階圖、CMYK、帶 alpha 通道的 PNG、EXIF 中的旋轉資訊。
- 正規化：使用 ImageNet 的均值與標準差，還是用自己這 20 類的統計量？在 200 張影像上估計統計量可靠嗎？請用實驗回答。
- 資料切分的位置：擴增是在切分之前還是之後做的？如果做錯順序會發生什麼事？請在報告中明確說明各組的順序。
- 批次與隨機性：亂數種子固定在哪些地方？哪些地方沒有固定？

Q2 解析度不一致的處理策略

ResNet-18 需要固定尺寸的輸入，但各位拿到的影像不是。請至少實作並比較下列策略中的三種，其中前兩種為必做：

策略	作法	必做／選做
直接縮放	不管長寬比，直接壓成 224x224	必做

策略	作法	必做／選做
等比縮放＋中心裁切	短邊縮到 256 後中心裁切 224×224	必做
等比縮放＋補邊	保持長寬比，以邊界值或均值填補成正方形	選做
多尺度／隨機縮放裁切	訓練時隨機取不同尺度的裁切區域	選做
超解析度前處理	對低解析度影像先放大再輸入	選做

除了策略本身，我還要各位回答兩個延伸問題：

9. 插值 Interpolation 方法（bilinear、bicubic、Lanczos、area）對結果有沒有影響？在放大與縮小的情況下，最佳選擇是否相同？
10. 把資料依原始解析度分成高、低兩群，各策略在這兩群上的表現差距如何？如果差距很大，代表什麼？

Q3 自訂的少樣本擴增方法（本次的重頭戲）

這一部分我刻意不給標準答案。請各組自行設計至少一個擴增方法，可以是既有方法的組合、改良，也可以是自己想出來的新作法。我看重的是「為什麼你認為這個方法對這批資料有用」，而不是方法多新穎。

以下只是幫助各位起步的思考方向，不是選項清單，也不必侷限於此：

11. 影像層級：幾何變換、色彩擾動、遮擋類（Cutout、Random Erasing）、混合類（Mixup、CutMix）、以及針對本資料集特性設計的變換。
12. 特徵層級：在 ResNet-18 特徵空間中做插值、加噪、或以類別原型為中心合成新樣本。
13. 針對弱點設計：先看清楚哪一類最差、錯在哪裡，再設計專門補救該弱點的擴增，而不是對所有類別一視同仁。
14. 擴增倍率：擴增到幾倍會開始沒有幫助，甚至變差？這個轉折點本身就是一個值得報告的發現。

一個小提醒

自訂擴增最常見的失敗，是做出「看起來很花俏、但改變了語意」的變換。例如把交通號誌做強烈色彩擾動，紅燈可能變成綠燈。

請在報告中放幾張擴增後的影像，並誠實檢查它們是否仍屬於原類別。發現自己的方法破壞語意並且說明清楚，比隱藏它更能得分。

必報指標

所有數字都必須是 3 組抽樣設定下的「平均值 ± 標準差」，只跑一次的結果不予採計。

指標	說明
Top-1 Accuracy	整體正確率，作為最基本的參考。
Macro-F1	本作業的主要指標，對少數類別敏感。
Per-class Recall	逐類別召回率，並標出最差類別。
最差類別 Recall	少樣本情境下最能反映真實可用性的單一數字。
混淆矩陣	至少對 M1 各提供一張。

$$\text{Macro-F1} = \frac{F_1 + F_2 + \dots + F_n}{n}$$

繳交項目與配分

項目	要求	配分
助教 Test 跑分	可從頭執行（Restart & Run All）	10%
尺寸策略比較 自訂擴增方法 3 頁 PDF 報告	- 至少 3 種策略的量化結果與高／低解析度分群分析 - 方法描述、實作、與傳統擴增的對照、擴增倍率分析 - 前處理決策說明、結果表、至少 3 張影像的失敗案例討論	15%

報告中請明確標示 M0 與 M1 的定義與數字，這兩個數字後面兩次都會用到。另請註明組員分工。

我批改第一次作業時，最常扣分的三件事

1. 只報告平均值、沒有標準差，或只跑一組抽樣就下結論。3 組抽樣設定請務必跑滿。
2. 只看整體 accuracy。少樣本問題的關鍵幾乎都藏在某一兩個類別的崩壞裡。
3. 報告中只描述數字（「策略 A 是 0.71，策略 B 是 0.74」），卻沒有解釋原因。我要看的是解釋，不是把表格用文字唸一遍。

四、第二次繳交：問題診斷、提出解法並實作

第 7 週繳交 | 占 20%

這一次的任務不是換一個題目，而是回頭把第一次做出來的東西當成研究對象。我要各位找出 M1 到底卡在哪裡，把它變成一個明確的問題，提出解法，並且真的動手做出 M2。這一次仍然禁止使用生成模型。

第一步：診斷

請至少完成下列四項診斷，並在提案中呈現證據。問題必須是「看出來的」，不是「猜出來的」：

1. 逐類別檢視混淆矩陣，找出哪兩類最常互相混淆，並實際把這些錯誤樣本印出來看。
2. 畫出學習曲線：每類 5、10、20 張真實影像時的 macro-F1。曲線是否已經飽和？如果沒有，代表瓶頸在資料量。
3. 比較訓練集與驗證集的表現差距，判斷目前是過擬合還是欠擬合。
4. 用 t-SNE 或 UMAP 看 ResNet-18 特徵的分布，觀察是否有類別重疊或群集破碎的現象。

第二步：把觀察寫成問題與假設

提案的核心是一個可以被推翻的假設，而不是一個目標。以下是我認為寫得夠好的範例：

「M1 在 C 類的 recall 只有 0.42，且其錯誤集中被判為 D 類。我們認為原因是這兩類在 ResNet-18 特徵空間中的類別原型距離過近，而非訓練樣本不足；因此提高擴增倍率不會改善，改用餘弦分類器並加入類別平衡權重才會。」

這句話之所以合格，是因為它指出了具體證據、提出了一個機制上的原因、預測了一個會失敗的作法，而且如果實驗結果是「提高擴增倍率就解決了」，這個假設就被推翻。「我們想讓準確率變高」不是假設，請不要這樣寫。

第三步：解法方向參考

以下對照表僅供起步，各組可自行提出其他方向，但請在第 4 週前找我確認可行性：

診斷出的問題	可以考慮的方向
兩類特徵重疊	餘弦分類器、原型／最近類別中心、度量學習、換用更深或不同層的特徵
某類別樣本過少而崩壞	類別平衡權重、重取樣、針對該類的特化擴增
嚴重過擬合	正規化強度、特徵降維、更簡單的分類器、特徵層級擴增
前處理造成資訊損失	改用其他尺寸策略、多尺度特徵串接、測試時擴增（TTA）
特徵本身不適合此任務	換用其他預訓練骨幹或中間層特徵，並公平比較參數量與成本

繳交項目與配分

項目	要求	配分
診斷證據	上述四項診斷的圖表與說明	5%

項目	要求	配分
6 頁 PDF 提案	問題陳述、假設、操作變因、固定條件、對照組、第 8-10 週排程與分工	10%
M2 初步實作	可執行的 Notebook，且 M2 與 M1 已在相同指標上完成初步比較	5%

必報指標與第一次相同（Accuracy、Macro-F1、Per-class Recall、最差類別 Recall），並附上 M1 與 M2 的差值。M2 不一定要比 M1 好；如果變差，請解釋為什麼，這同樣可以拿到高分。

提案我會逐組給書面回饋，通常在第 6 週初發還。這些回饋不是參考建議，第三次繳交時我會檢查各組是否處理過。

五、第三次繳交：Diffusion 生成資料與四代模型比較

第 10 週繳交 | 占 25%

這一次，各位要用 diffusion model 生成假的訓練樣本，把它們加入訓練資料得到 M3，然後和 M1、M2 在一整組指標上正面比較。我要再強調一次：這一次的評分重心是解釋，不是數字。

生成流程與統一設定

為了讓各組結果可以互相比較，生成端的設定請一律固定如下：

設定項目	數值
模型	Stable Diffusion 1.5
影像解析度	512 × 512
Scheduler	DDIM (Denoising Diffusion Implicit Model)
取樣步數	30 步
Guidance scale	7.5
批次大小	每批 1 張
隨機種子	使用我提供的固定 seed 清單，並完整記錄

Prompt 策略由各組自行設計，但至少包含下列兩種並做對照：

15. 基本提示：僅描述類別，例如 A photo of a bus.
16. 多樣提示：加入背景、視角、光照等變化，例如 A photo of a bus on a rainy city street, viewed from the side.

這組對照是刻意設計的。如果多樣提示明顯優於基本提示，那代表有效的不是「生成」本身，而是生成資料所帶來的分布多樣性。請在報告中正面回應這一點。

每張生成影像都必須記錄其 prompt、seed、提示類型與生成參數，並隨 Notebook 一併繳交。無法追溯來源的生成資料不予採計。

必做的比較矩陣

下列每一列都必須跑滿 3 組抽樣設定：

模型	訓練資料組成	用途
M0	僅真實影像	絕對基準線
M1	真實 + 自訂擴增	第一次的成果
M2	M1 + 第二次的改良解法	第二次的成果
M3	M2 + diffusion 生成資料	本次的主角
M3-a	真實 + diffusion（不含自訂擴增）	分離兩種擴增的貢獻
M3-r	M3 但改變合成／真實比例	至少 4 個比例點，用於找飽和或反轉點

合成比例建議取每類 0、10、20、40、60 張生成影像，各組可依實際情況調整，但至少要有 4 個點才畫得出趨勢。

必報指標

以下四組指標為強制項目。所有數值都必須是 3 組抽樣設定下的「平均值 ± 標準差」，並以表格或圖形同時呈現 M0、M1、M2、M3。

A. 分類效能（主要指標）

指標	說明	呈現方式
Top-1 Accuracy	整體正確率	表格
Macro-F1	本作業的首要決策指標	表格 + 長條圖
Balanced Accuracy	各類 recall 的平均，補足類別不均的影響	表格
Per-class Precision / Recall / F1	逐類別呈現，四代模型並列	表格
最差類別 Recall	少樣本可用性的關鍵單一數字	表格
Macro AUROC（one-vs-rest）	不受決策門檻影響的排序能力	表格

指標	說明	呈現方式
混淆矩陣	至少 M0 與 M3 各一張，並標出變化最大的格子	圖

關於統計的正確說法

3 組抽樣設定的標準差反映的是抽樣變異，不等同於統計顯著性。

請不要在報告中使用「顯著提升」這個詞。正確的說法是：M3 的 Macro-F1 為 0.74 ± 0.03 ，M2 為 0.71 ± 0.02 ，兩者的誤差範圍有重疊，因此本實驗無法排除差異來自抽樣變異的可能。

有能力的組別可以另外做配對比較（同一 seed 下的差值）並回報其平均與標準差，這比直接比較兩個獨立的平均值更有說服力。

報告必須正面回答的五個「為什麼」

這一節是第三次繳交的核心，也是我配分最重的部分。每一題都必須有實驗數據或影像證據支撐，只有推測不予計分。

1. 為什麼生成資料在某些類別有幫助、在另一些類別沒有？請用 C 組指標與實際影像來解釋類別間的差異。
2. 生成資料帶來的增益，究竟來自「樣本變多」還是「分布變多樣」？請設計一個能把這兩者分開的對照（提示：在總樣本數相同的前提下比較自訂擴增與生成資料）。
3. 生成資料與真實資料的分布差距（KID/MMD/原型距離），和效能增益之間有沒有關係？請畫出散點圖，並說明看到或沒看到關係代表什麼。
4. 效能是否隨合成比例飽和甚至反轉？轉折點在哪裡？請提出一個機制上的解釋，並用資料檢驗它。
5. 第二次的改良（M2）與第三次的生成資料，兩者的效果是相加、重疊，還是互相抵消？請用 M1、M2、M3-a、M3 這四個點來論證。

繳交項目與配分

項目	要求	配分
完整 Notebook 與助教跑分	可重現所有主要實驗；含生成紀錄、環境與設定說明	5%
指標結果 五個「為什麼」的分析	A - D 四組必報指標齊備，四代模型並列，含平均值與標準差 每題均有實驗或影像證據支撐的解釋	10%
10 頁 PDF 報告	問題、方法、結果、至少 3 個失敗案例、限制與分工	5%
簡報與口頭展示	8 分鐘報告 + 4 分鐘問答，並繳交簡報檔	5%

請各位放心的一件事

M3 沒有比 M2 好，仍然可以拿到不錯的分數。

各位可以從配分看出我的立場：五個「為什麼」的分析佔 10%，比任何一項效能數字都重。一組誠實地發現「生成資料在這個設定下沒有幫助」，並用 KID、類別一致性率與最近鄰相似度說明為什麼、指出在什麼條件下才可能有幫助的報告，分數會高於一組靠反覆試參數把數字調上去、卻說不清楚原因的報告。

如果各位在最後一週開始想著要怎麼把數字弄好看，代表方向已經偏了，請來找我談。

六、參考資源

生成模型：Stable Diffusion 1.5

<https://huggingface.co/stable-diffusion-v1-5/stable-diffusion-v1-5>

如果各位在任何一個階段卡住，請不要拖到繳交前一天。我的辦公時間與課後時間都歡迎各位來討論，帶著具體的數字或錯誤訊息來，我們可以談得比較有效率。祝各位做出自己會想拿給別人看的成果。